

PROJEKTNI ZADATAK – NEURALNE MREŽE - 2024/25

Pripremile – Katarina Brkljač 0309/2022 i Milica Bjelovuk 0465/2022

(S = 8)

ZADATAK 1 - Projektovanje potpuno povezane neuralne mreže

Karakteristike skupa podataka Star.csv:


- *Broj uzoraka* - 5852
- *Broj obeležja* – 8 (Mean IP, Std IP, Excess kurtosis IP, Skewness IP, Mean DM-SNR, Std DM-SNR, Excess kurtosis DM-SNR, Skewness DM-SNR)
- *Broj klasa* – 2 (0 - nije zvezda, 1 - jeste)
- *Priroda klasifikacionog zadatka* – binarna klasifikacija za prepoznavanje zvezda na osnovu radio signala. U datom skupu ima 4213 (72%) uzoraka nulte i 1639 (28%) uzoraka prve klase, tako da skup nije potpuno balansiran – to može dovesti do pristrasnosti mreže većinskoj klasi. Treba nam regularizacija da ne bi došlo do overfitting-a ka manjoj klasi. Za binarnu klasifikaciju je pogodna sigmoid aktivaciona funkcija.

Izbor i obrazloženje:

- *Kriterijumska funkcija* – Binary cross-entropy. Merenje divergencije između predviđenih verovatnoća i istinitih labela za binarne probleme, sa formulom
$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)],$$
gde je y_i labela, a p_i predviđena verovatnoća. Ova funkcija je derivabilna i pogodna za gradijentni spust. Idealna za nebalansirane binarne podatke, jer bolje penalizuje greške na retkoj klasi nego MSE, koja bi ignorisala verovatnoće i dovela do loše konvergencije na numeričkim signalima.
- *Funkcije aktivacija neurona* –
 - Skriveni sloj: ReLU (Rectified Linear Unit). Formula: $f(x) = \max(0, x)$. ReLU uvodi nelinearnost, rešava vanishing gradient problem (gradijenti ne nestaju za pozitivne ulaze) i omogućava sparse aktivacije. Efikasna za numeričke statističke mere signala, jer ubrzava trening na nebalansiranom datasetu i smanjuje rizik od overfittinga. Bolja je od tanh jer izbegava saturaciju i podržava bržu konvergenciju na ovakvim podacima.

- Izlazni sloj: Sigmoid. Mapira ulaz u $[0,1]$ sa funkcijom $f(x) = \frac{1}{1+e^{-x}}$, interpretacija bude kao verovatnoća, sa izvodom $f'(x) = f(x)(1 - f(x))$ za backpropagation. Standardno je za binarnu klasifikaciju, pruža verovatnoću za threshold (npr. 0.5), što je korisno za nebalansirane skupove. Za razliku od hardlim (koji je diskretan i ne pruža gradijent za optimizaciju), sigmoid omogućava kontinuirano učenje i bolju evaluaciju.
- *Metoda optimizacije – Adam* (Adaptive Moment Estimation). Kombinuje momentum i RMSprop, sa ažuriranjem $\theta_t = \theta_{t-1} - \frac{\eta \hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$ ($\hat{m}_t$ i $\hat{v}_t$ su momenti gradijenata). Efikasno za nebalansirane skupove poput ovog (4213:1639), jer adaptivno prilagođava learning rate po parametru. Brža je od SGD i stabilnija za radio signale.

Histogram raspodele odbiraka po klasama:



Korišćen je early stopping, kao i dropout sloj za izbegavanje overfittinga (kod nebalansiranih skupova podataka mreža može da se prilagodi većem podskupu i u treningu daje odlične rezultate, dok se na testu pokaže jako loše na novim podacima).

Hiperparametri:

- broj neurona u skrivenom sloju* [16,32,64] – kapacitet modela (koliko obrazaca može da nauči; više neurona može dovesti do overfittinga)
- dropout rate* [0, 0.2, 0.25] – regularizacija (nasumično isključivanje neurona iz mreže da ne bi došlo do overfittinga)
- Adam learning rate* [0.001, 0.01, 0.1] – brzina ažuriranja težina modela (veća stopa ubrzava učenje, manja godi preciznosti)


```
Epoch 15/100
Epoch 16/100
Epoch 16: early stopping
Restoring model weights from the end of the best epoch: 11.

Trial 5 Complete [00h 00m 04s]
val_accuracy: 0.9626467227935791

Best val_accuracy So Far: 0.9626467227935791
Total elapsed time: 00h 00m 15s
Najbolji hiperparametri: {'neurons': 64, 'dropout_rate': 0.0, 'learning_rate': 0.1}
```

Grafik promena performansi tokom epoha treniranja (za trening i validacioni skup):

Grafik prikazuje rast tačnosti tokom epoha, dok validacioni gubitak može ukazivati na overfitting ako raste nakon određenog broja epoha. Early stopping sprečava preterano učenje tako što zaustavi obučavanje nakon par uzastopnih porasta validacionog gubitka.



Vrednosti performansi klasifikacije (tačnost, preciznost, osetljivost, f1-skor, ROC AUC)[0-1]:

```
Tačnost: 0.9666951323654995
Preciznost: 0.9616613418530351
Osetljivost (Recall): 0.9176829268292683
F1-skor: 0.9391575663026521
roc auc: 0.9517240256922144
```

-*tačnost* – tačno predviđene klase (može favorizovati dominantniju)

-*preciznost* – tačno predviđeni pozitivni uzorci od svih pozitivnih (detektuje lažne pozitivne)


-*osetljivost* – tačno prepoznati stvarni pozitivni od svih stvarnih pozitivnih (detekcija svih pravih 1; u skupu podataka ima više 0 nego 1, tako da je ovo važno)

-*F1 skor* – harmonijska sredina preciznosti i osetljivosti (uзима u obzir i 1 i 0)

-*ROC AUC* – površina ispod krive (true vs false 1; koliko dobro mreža razaznaje klase – ukupne performanse)

Matrice konfuzije na trening i test skupu:

Matrice konfuzije pokazuju tačnost klasifikacije po klasi. Dijagonalni elementi su tačno klasifikovani primeri, dok oni van dijagonale ukazuju na greške. Test skup pokazuje generalizaciju modela. Razlika između trening i test matrice može ukazivati na generalizaciju modela – ako je test matrica lošija, može postojati overfitting.




ZADATAK 2 - Projektovanje potpuno konvolucione neuralne mreže

Karakteristike skupa podataka *Brain Tumor MRI Multi-Class Dataset*¹:

- *Tip ulaznih podataka* – slike u različitim formatima (.jpg, .jpeg, .png), različitih veličina – potrebno je odraditi normalizaciju (skaliranje piksela da bi se izbegao eksplodirajući/nestajući gradijent, kao i resize slika) jer MRI slike imaju varijacije u intenzitetu (kontrast i osvetljenje).
- *Broj i naziv klasa* – 4 klase u ukupno 16269 slika:
 - Glioma – 3325 (20,4%)
 - Meningioma – 3266 (20,1%)
 - Pituitary – 2974 (18,3%)
 - Healthy – 6704 (41,2%)

Ovo je nebalansiran skup podataka (najzastupljenija je Healthy), što znači da ćemo koristiti augmentaciju podataka i dropout sloj, da ne bi došlo do overfittinga.

- *Grafik* – broj uzoraka po klasama



¹ (preuzeto sa <https://www.kaggle.com/datasets/maxwellbernard/brain-tumor-mri-multi-class-dataset/data>, 20.10.2025)

Primenjene transformacije u predprocesiranju i obrazloženja:

1. Skaliranje slike na 240x240:

- Svrha – CNN ulazi treba da budu istih dimenzija, treba odabrati veličinu koja neće isključiti važne detalje
- Uticaj na model – manja veličina slike ubrzava trening i pospešuje stabilnu konvergenciju, ali može doći do gubitka preciznosti ako se izgube finiji detalji slike

2. Normalizacija piksela:

- Svrha – izbegavanje eksplodirajućeg/nestajućeg gradijenta zbog varijacija u intenzitetu piksela
- Uticaj na model - poboljšava brzinu konvergencije, smanjuje overfitting na varijacijama intenziteta i povećava tačnost, mreža brže uči s manjim oscilacijama

3. Augmentacija podataka:

- Svrha – povećavanje raznovrsnosti podataka
- Uticaj na model – smanjuje overfitting i poboljšava generalizaciju i tačnost kod test primeraka

Izbor i obrazloženje:




- **Kriterijumska funkcija - Categorical cross-entropy.** $L = - \sum_{i=1}^C y_i \log(p_i)$, gde je $C=4$. Pogodna je za nebalansiranu multiklasnu klasifikaciju, koristi se sa `class_weight` za težinsko balansiranje.
- **Funkcije aktivacija neurona –**
 - Skriveni sloj (conv/dense): ReLU. $f(x) = \max(0, x)$. Efikasna za feature extraction
 - Izlazni sloj: Softmax. $p_i = \frac{e^{z_i}}{\sum e^{z_j}}$. Standardno je za više ekskluzivnih klasa.
- **Metoda optimizacije – Adam (Adaptive Moment Estimation).** Kombinuje momentum i RMSprop, sa ažuriranjem $\theta_t = \theta_{t-1} - \frac{\eta \hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$, gde su m_t i v_t momenti gradijenata. Efikasno za nebalansirane skupove poput ovog.

Da ne bi došlo do overfitting-a korišćena je early stopping tehnika, kao i dropout sloj.


```
Epoch 32: early stopping
```

```
Restoring model weights from the end of the best epoch: 27.
```

Po jedan primerak iz svake klase:



Augmentacija podataka na trening skupu:



Arhitektura modela I parametri:

```
Found 13014 files belonging to 4 classes.
Using 2602 files for validation.
Found 3255 files belonging to 4 classes.
['glioma', 'healthy', 'meningioma', 'pituitary']
2025-10-27 20:47:40.850495: I tensorflow/core/framework/local_rendezvous.cc:4
C:\Users\Milica Bjelovuk\PycharmProjects\nmprojmb\.venv\Lib\site-packages\ker
super().__init__(**kwargs)
2025-10-27 20:47:41.871280: I tensorflow/core/framework/local_rendezvous.cc:4
Model: "sequential_1"
```

Layer (type)	Output Shape	Param #
sequential (Sequential)	(None, 240, 240, 3)	0
rescaling (Rescaling)	(None, 240, 240, 3)	0
conv2d (Conv2D)	(None, 240, 240, 8)	224
max_pooling2d (MaxPooling2D)	(None, 120, 120, 8)	0
conv2d_1 (Conv2D)	(None, 120, 120, 16)	1,168
max_pooling2d_1 (MaxPooling2D)	(None, 60, 60, 16)	0
conv2d_2 (Conv2D)	(None, 60, 60, 32)	4,640
dropout (Dropout)	(None, 60, 60, 32)	0
flatten (Flatten)	(None, 115200)	0
dense (Dense)	(None, 64)	7,372,864
dense_1 (Dense)	(None, 4)	260


Total params: 7,379,156 (28.15 MB)

Trainable params: 7,379,156 (28.15 MB)

Non-trainable params: 0 (0.00 B)

Grafik promena performansi tokom epoha treniranja (za trening i validacioni skup):

Grafik prikazuje rast tačnosti tokom epoha, dok validacioni gubitak može ukazivati na overfitting ako raste nakon određenog broja epoha. Early stopping zaustavlja treniranje ako se za validacioni skup tačnost nije popravila nakon 5 epoha, čime se sprečava preterano učenje.



Vrednost performansi klasifikacije:

Tačnost je izračunata za sve skupove, a dodatne metrike (preciznost, osetljivost, F1-skor) za validacioni skup pokazuju performanse po klasi. Ako su vrednosti niske (npr. <70%), to može ukazivati na neravnotežu klasa ili potrebu za boljom arhitekturom modela.


```
Tačnost na trening skupu: 91.06%
Tačnost na validacionom skupu: 89.32%
Tačnost na test skupu: 89.00%
```

Metrike za validacioni skup:

	precision	recall	f1-score	support
glioma	0.90	0.78	0.84	536
healthy	0.93	0.96	0.95	1064
meningioma	0.79	0.81	0.80	524
pituitary	0.91	0.96	0.93	478
accuracy			0.89	2602
macro avg	0.88	0.88	0.88	2602
weighted avg	0.89	0.89	0.89	2602

Matrice konfuzije – trening i test skup:


Matrice konfuzije pokazuju tačnost klasifikacije po klasi. Dijagonalni elementi su tačno klasifikovani primeri, dok oni van dijagonale ukazuju na greške. Test skup pokazuje generalizaciju modela. Razlika između trening i test matrice može ukazivati na generalizaciju modela – ako je test matrica lošija (više od 2-5% lošija), može postojati overfitting.




Primeri dobro i loše klasifikovanih slika iz skupa podataka:

Dobro klasifikovane slike pokazuju usklađenost između stvarne i predviđene klase, dok loše klasifikovane ukazuju na potencijalne probleme poput sličnosti između klasa (npr. glioma i meningioma) ili nedostatka podataka. Ovo može pomoći u identifikaciji slabih tačaka modela.


Dobro: healthy -> healthy




Dobro: glioma -> glioma



Loše: glioma -> meningioma



Loše: meningioma -> healthy




ZADATAK 3 - Projektovanje fuzzy regulatora

Prvi zahtev

U prvom zahtevu je traženo da se projektuje proizvoljan fuzzy sistem upravljanja za praćenje referentne vrednnosti upravljanja pomoću simulink modela u zatvorenoj sprezi.

Opredelile smo se za intuitivni model upravljanja za fuzzy sistem koji će kontrolisati nivo vode u bazenu, gde su ulazne vrednosti odstupanje od željene popunjenosti bazena.

Scenario: bazen je dubok 3m, pretposatavka je da je optimalna popunjenost 2.5m. Ako je ulazna vrednost -2.5m to znači da je bazen prazan (odstupa za 2.5m od ciljane popunjenosti bazena). Izlaz mamdani fuzzy sistema je protok pumpe. Pravila kao I izgled fuzzy logic controllerje:



System: kontrolaBryine			
Add All Possible Rules Clear All Rules			
	Rule	Weight	Name
1	If water_level is VeryLow then pump_flow is VeryHigh	1	rule1
2	If water_level is Low then pump_flow is High	1	rule2
3	If water_level is Medium then pump_flow is Medium	1	rule3
4	If water_level is High then pump_flow is Low	1	rule4
5	If water_level is VeryHigh then pump_flow is VeryLow	1	rule5

Varijanta S koju imamo nam dodeljuje vrednosti:


8	$G(s) = \frac{-0.2s+0.01}{(s+0.1)^2}e^{-4s}$	$r \in [-1, +1]$	$u \in [-1.5, +1.5]$
---	--	------------------	----------------------

Prvo smo napravile pobudni signal na osnovu definisanih vrednosti u G(S), rezultat te transfer funkcije je grafik:




a izgled šeme je:

Transfer funkcija:




gde je e^{-4s} definisan unutar Delay komponente. Na osnovu grafika zaključujemo da je pobudni signal optimalan, dakle greška je 0, stoga i kada se stavi povratna sprega, rezultujući grafik će biti identičan.



Implementacijom povratne sprega sa fuzzy kontrolerom koji je ranije opisan dobija se regulisana varijabla (plava boja, žutom je opisan samo signal dobijen iz scope):



Povratna spega bez integratora;




Problem ove regulisane varijable je u tome što njena vrednost osciluje kroz vreme i to oko -0,5 i 0.5, što nije željeno ponašanje; cilj je da se osciluje oko vrednosti -1 i 1. Kako bismo rešili ovaj problem, dodaje se integrator u šemu:



Sad su oscilacije „rasute“, dakle cilj je da se ukloni ova oscilacija sa komponentom gain. Nakon više pokušaja najoptimalnija vrednnost K za ovaj sistem je -0,02. Kada se on doda u šemu dobije se željeni grafik upravljanja (1. grafik sa samo žutom linijom), grafik regulisane varijable (2. grafik, 2 linije):



Konacna sema




Drugi zahtev

Drugi deo zadatka traži da se projektuje sistem fuzzy upravljanja za potiskivanje nemerljivog poremećaja na ulazu objekta upravljanja s parametrima:

8	$G(s) = \frac{-0.2s+0.01}{(s+0.1)^2}e^{-4s}$	$r \in [-1, +1]$	$u \in [-1.5, +1.5]$
---	--	------------------	----------------------

Takođe se traži da je maksimalna amplituda poremećaja jednaka polovini maksimalne amplitude upravljačkog signala. Razlike između šeme koja rešava ovaj i prethodni zahtev je u tome što je maksimalna amplituda poremećaja u ovom zahtevu opsegu od -0,75 i 0,75 i što je referenca sada $r=0$.

Prva verzija šeme ispunjava sve uslove osim uslova vezanog za maksimalnu amplitudu:




Koristi se isti fuzzy sistem za punjenje bazena kao i ranije. Rezultat ove šeme su grafici za:


-Signal regulisane varijable(plava linija) i signal poremećaja:



-Signal upravljanja:




-Signal nakon izlaza iz integratora:




Sada, kako bi se ograničila maksimalna amplituda poremećaja, potrebno je izmeniti .fis fajl koji se koristi u ovoj, kao i u šemama u 1. zahtevu.

Stare vrednosti:




Nove vrednosti:




Šema ostaje ista, jedino što se razlikuje je korišćenje „kontrolaBrzineV2.fis“ fuzzy kontrolera umesto „kontrolaBrzine.fis“ kao u ostalim šemama.

Rezultujući signali su:

-Signal regulisane varijable(plava linija) i signal poremećaja(žuta linija):



-Signal upravljanja:



-Signal nakon izlaza iz integratora:

